Анализ больших данных с Apache Spark

Лекция 1. Парадигма MapReduce и концепция вычислений на Spark

Мурашкин Вячеслав
2017

https://github.com/a4tunado/lectures-hse-spark/tree/master/001

Лекция 1.1 Парадигма MapReduce

- Почему MapReduce?
- Парадигма MapReduce
- Распределенное хранилище: HDFS
- Экосистема приложений Hadoop

Почему MapReduce?

- Алгоритмы работающие на одном сервере сложно масштабировать при увеличении объема данных
- В случае разделения вычислительных ресурсов и хранилища возникает узкое место при переносе данных, решение: перенести вычисления к данным
- Сервер с мощным CPU, как правило, стоит дороже, чем эквивалентное число более слабых машин
- Возникла потребность в **отказоустойчивом** решении для обработки большого объема данных **дешево** с простым способ **масштабирования** без изменения логики работы алгоритмов

Парадигма MapReduce

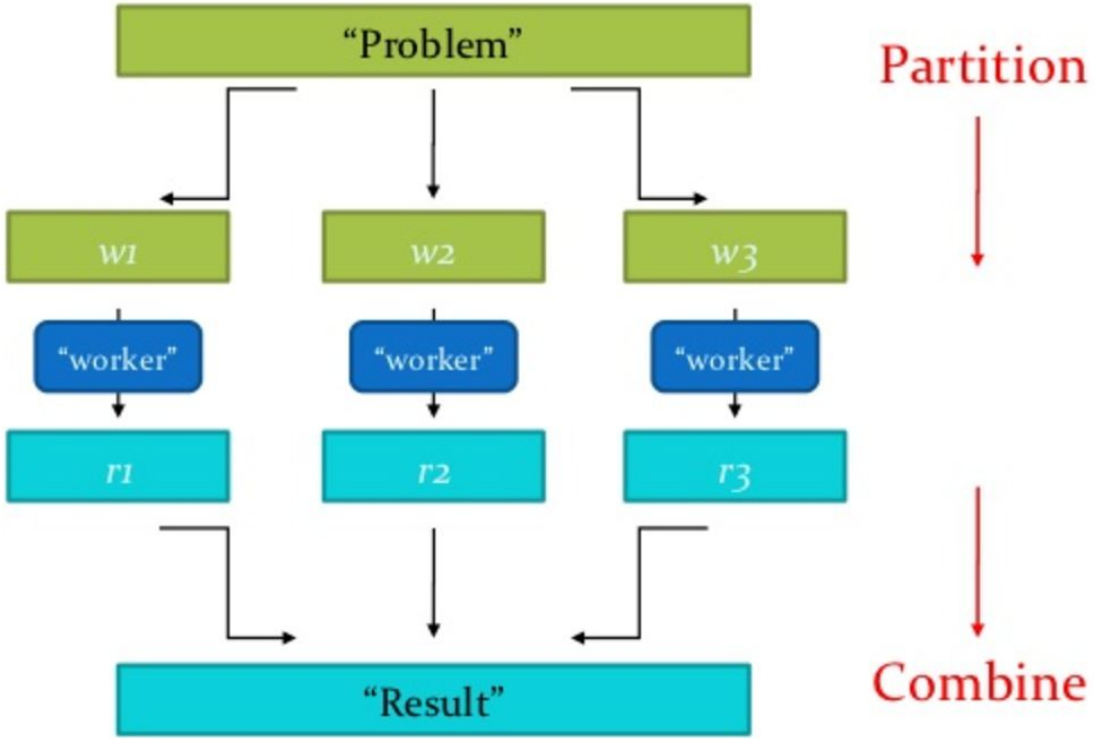

Парадигма MapReduce

- Данные на входе и выходе алгоритма всегда передаются в виде **набора** пар **<key, value>**
- Для обработки данных необходимо реализовать **две** функции:

  map (in_key, in_value) -> list(out_key, intermediate_value)

  - принимает на входе пару <in_key, in_value>
  - возвращает список пар с промежуточными значениями <out_key, intermediate_value>

  reduce (out_key, list(intermediate_value)) -> list(out_key, out_value)

  - обрабатывает промежуточные значения для ключа out_key
  - возвращает результат обработки в виде списка (как правило из одного элемента)

Пример: подсчет частот слов в корпусе

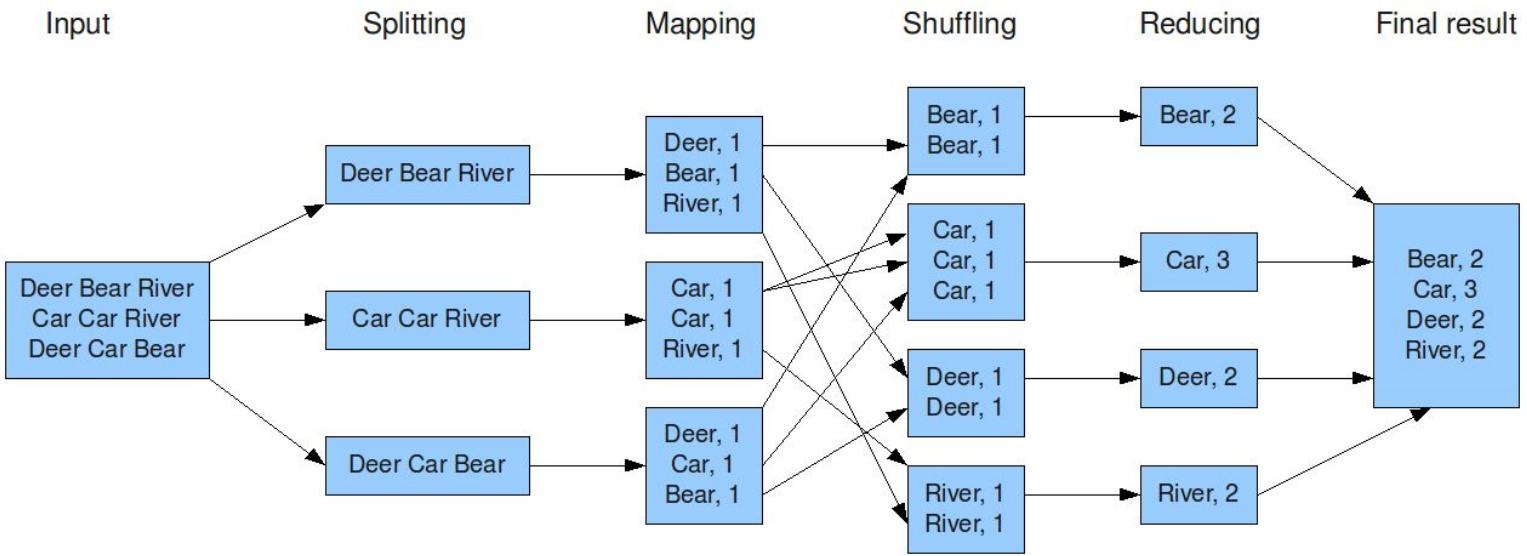

Пример: подсчет частот слов в корпусе

```
map(String input_key, String input_value):
  // input_key: document name; input_value: document contents
  for each word w in input_value:
    EmitIntermediate(w, "1");

reduce(String output_key, Iterator intermediate_values):
  // output_key: a word; output_values: a list of counts
  int result = 0;
  for each v in intermediate_values:
    result += ParseInt(v);
  Emit(output_key, AsString(result));
```

Плюсы и минусы

+ Map и reduce стадии легко параллелятся
+ Линейное масштабирование
+ Отказоустойчивость: независимая обработка данных, в случае падения одной машины не нужно перезапускать весь процесс заново

- Данные после каждого этапа сохраняются на диск (тратим время на запись/чтение данных)
- Необходимо копировать данные после map стадии (группировка по ключу)

Распределенное хранилище: HDFS

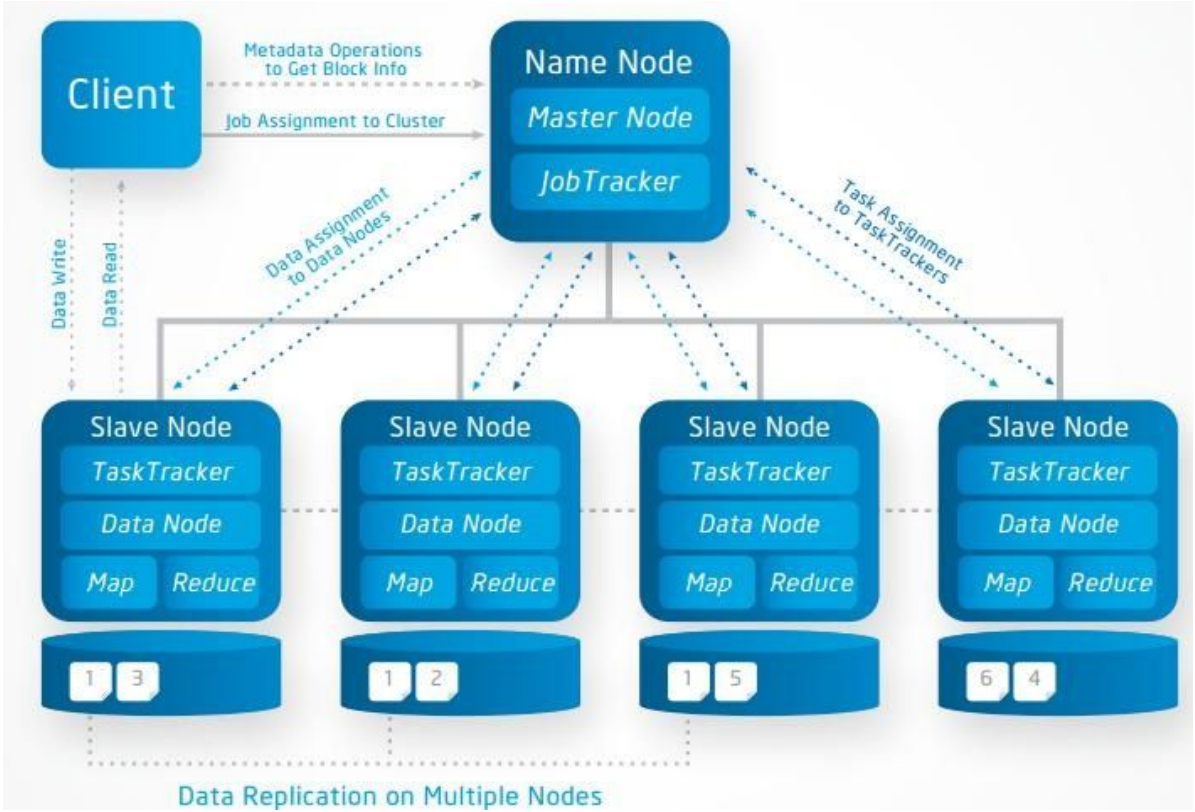

Экосистема Hadoop

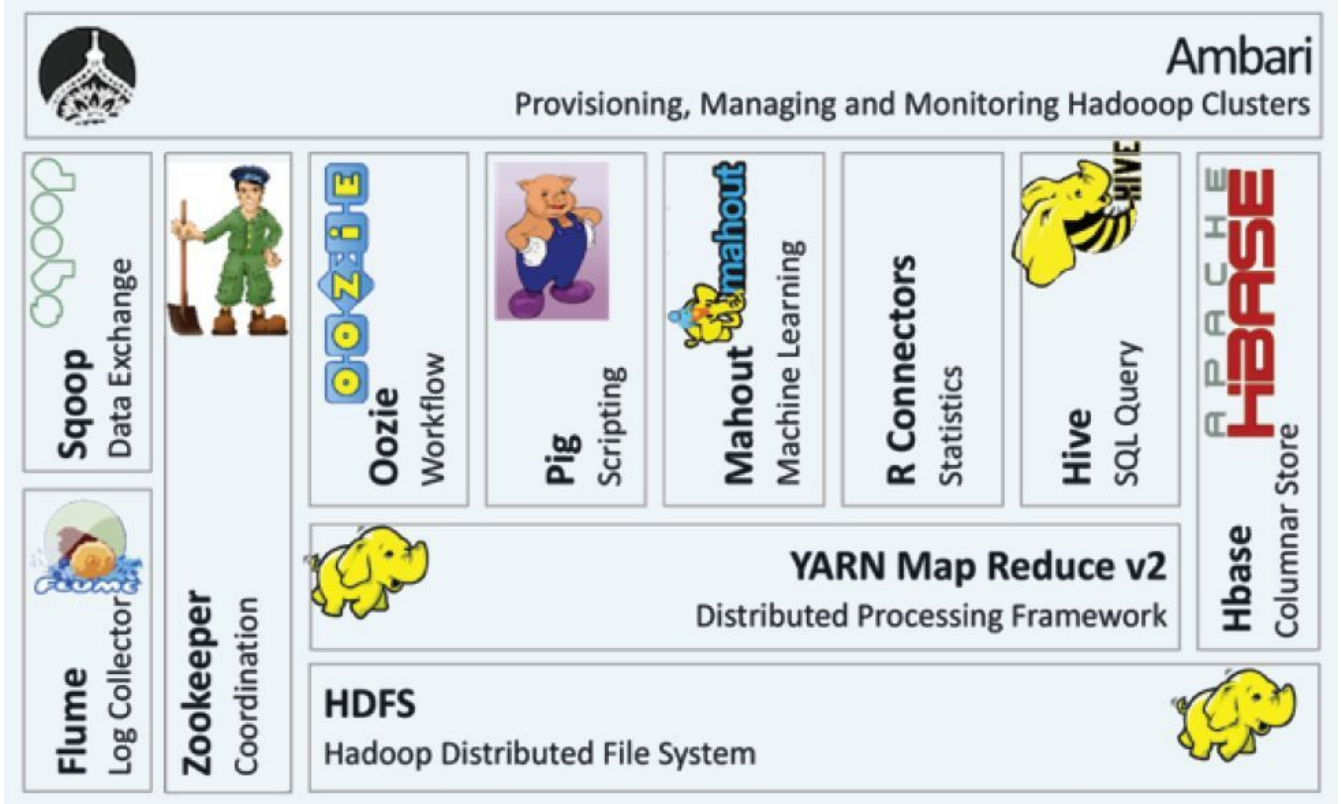

Лекция 1.2 Концепция вычислений на Spark

- Недостатки MapReduce
- Распределенные вычисления в памяти
- RDD (Resilient Distributed Datasets)
- Архитектура Spark
- Концепция вычислений на Spark
- Задание: реализовать обучение модели логистической регрессии на Spark

Недостатки MapReduce

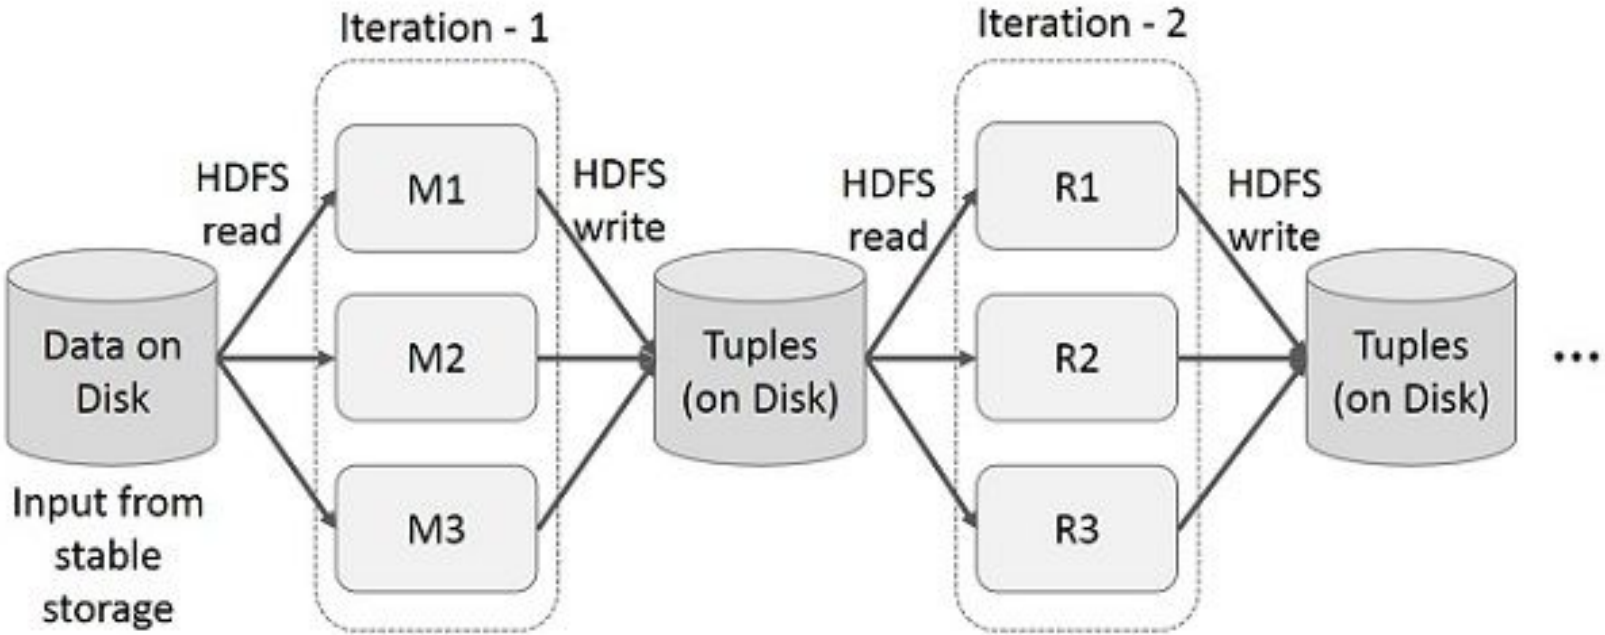

Распределенные вычисления в памяти

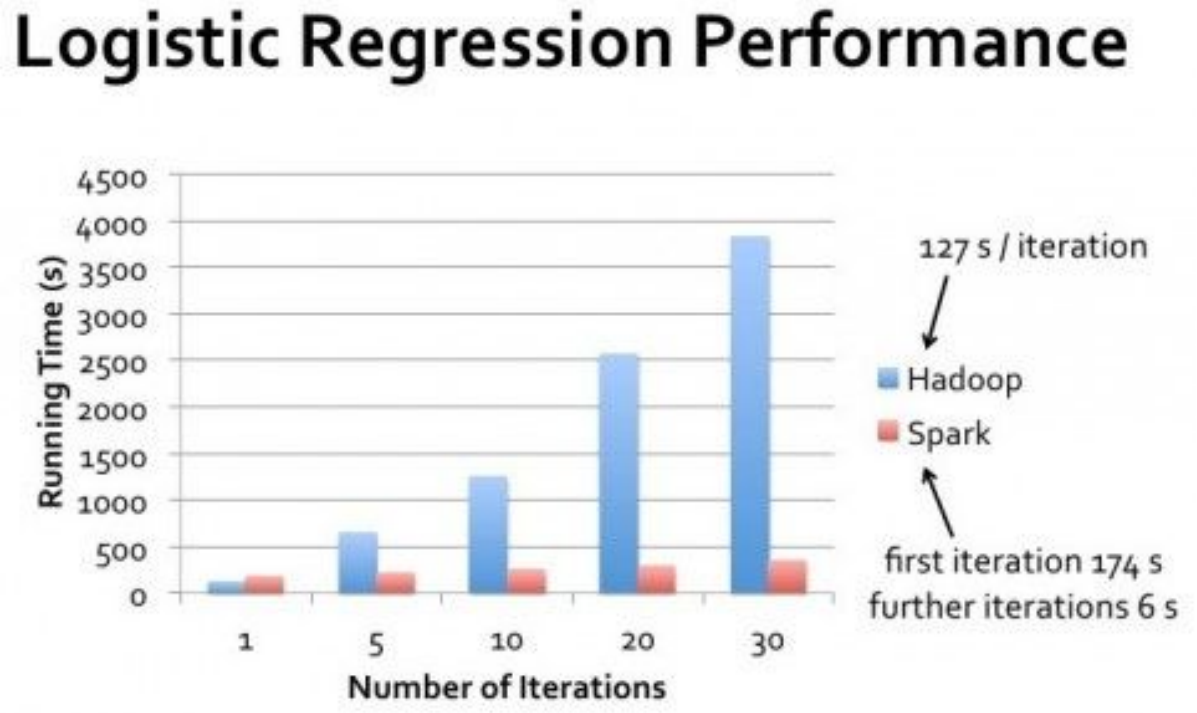

RDD (Resilient Distributed Datasets)

- Основной способ представления данных в Spark
- Read-only
- Представляет собой набор объектов одного типа
- Каждый набор данных в RDD может быть разбит на логические части (chunk) и размещен на разных машинах кластера
- Может хранится как на жестком диске, так и в оперативной памяти
- Новый RDD можно получить загрузив данные из распределенного хранилища (HDFS), либо путем преобразования другого RDD
- https://cs.stanford.edu/~matei/papers/2012/nsdi_spark.pdf

RDD (Resilient Distributed Datasets)

- Управление настройками RDD
  - partitioning (repartition)
    - способ разбиения данных на логические части (chunk)
  - persist (MEMORY_ONLY, MEMORY_AND_DISK, ...)
    - определяет место хранения данных, полезно если все данные не помещаются в память
  - unpersist
    - удаляет данные и высвобождает память

RDD (Resilient Distributed Datasets)

- Поддерживаются два типа операций:
  - преобразования (map, reduceByKey, join, ...)
    - задают преобразование отдельно для каждой строки
    - возвращают ссылку на новый RDD
    - вычисления по требованию (lazy computations)
    - сохраняется последовательность преобразований для восстановления в случае отказа ноды кластера
  - действия (min, max, count, ...)
    - инициируют расчет и возвращают значения

Apache Spark

- Высокопроизводительная система распределенных вычислений
- Основная часть реализована на *функциональном* языке Scala
- Поддерживает API для Python, Java, Scala и R
- Основные компоненты
  - SparkSQL
  - MLlib
  - Spark Streaming
  - GraphX

Apache Spark

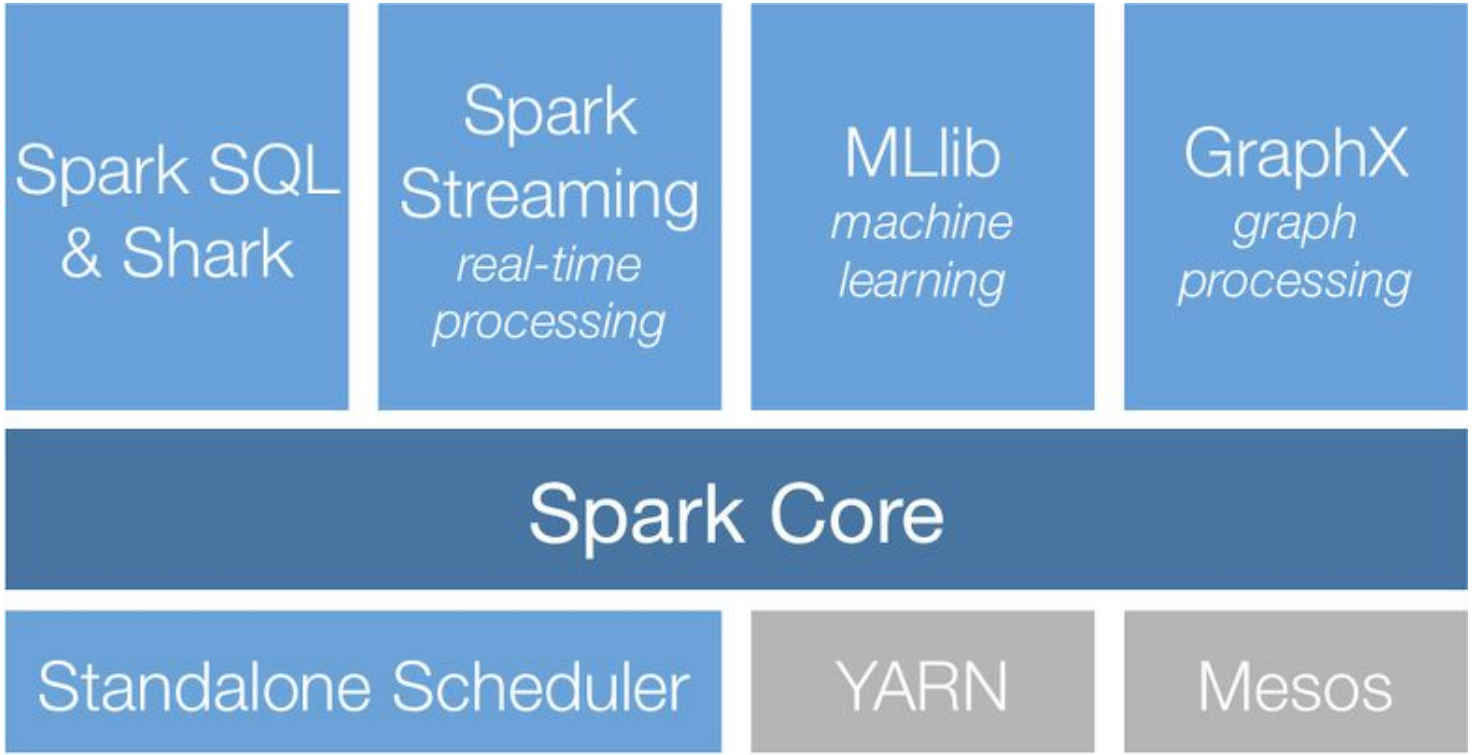

Концепция вычислений на Spark - SparkContext

- SparkContext
  - один экземпляр на приложение
  - создание RDD и хранение мета информации
    - sc.parallelize
    - sc.textFile
    - sc.wholeTextFiles
  - отвечает за запуск приложений на Spark кластере
  - управление настройками и процессом выполнения приложений
  - получение информации о статусе выполнения приложений

Концепция вычислений на Spark

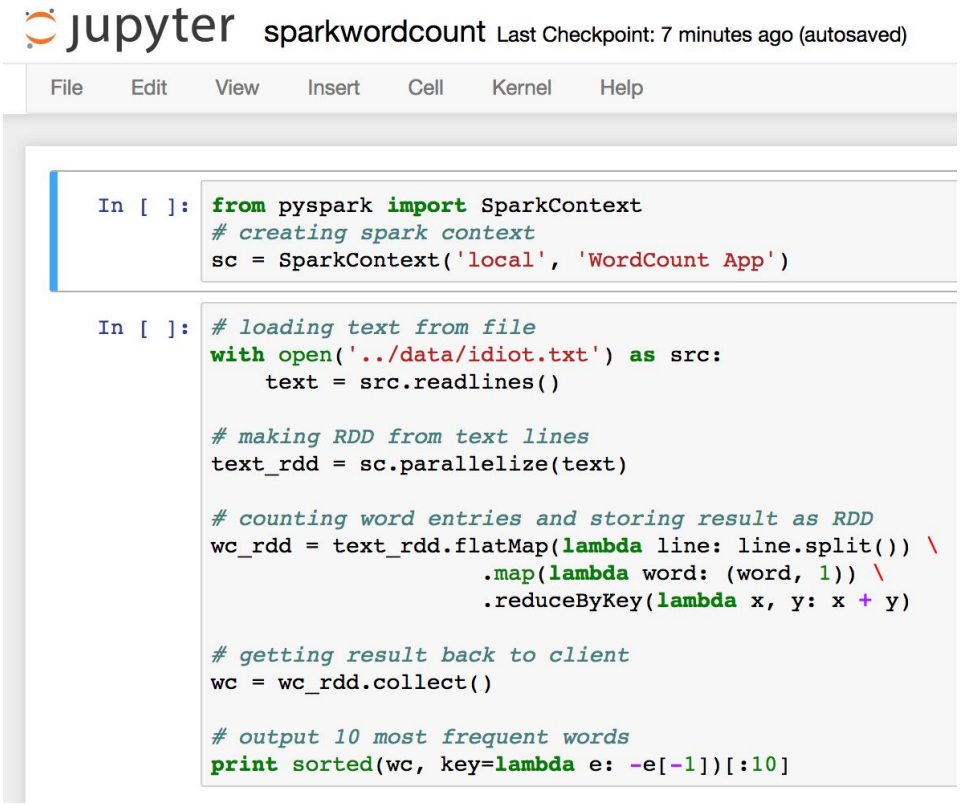

Концепция вычислений на Spark - flatMap

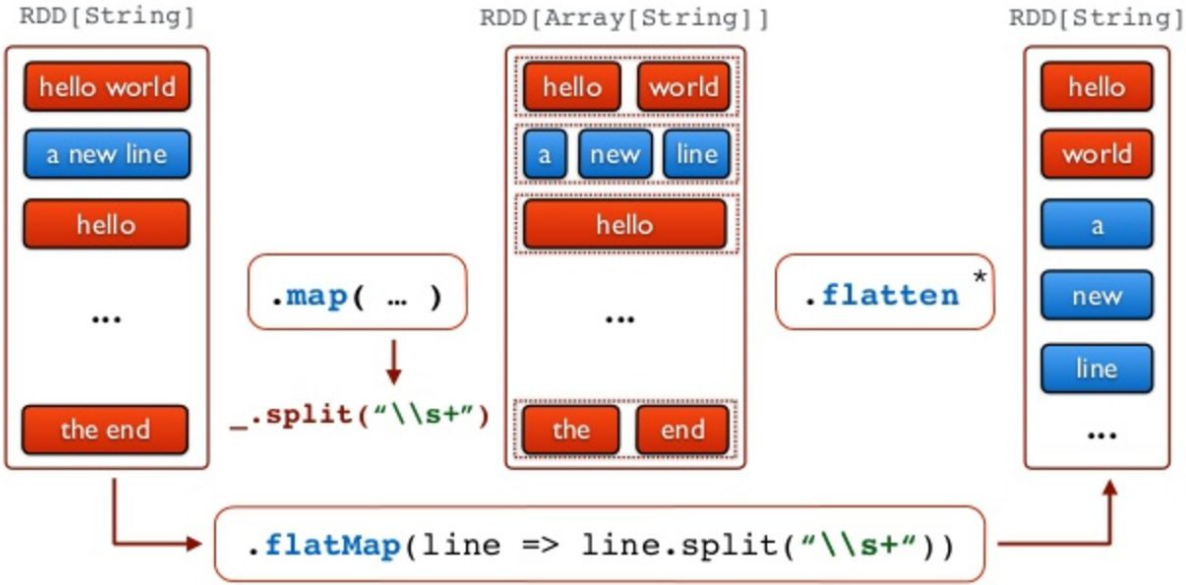


```
// Step 3 - Split lines into words
val words   = lower.flatMap(line => line.split("\\s+"))
```

Note: flatten() not available in spark, only flatMap

Концепция вычислений на Spark - reduceByKey

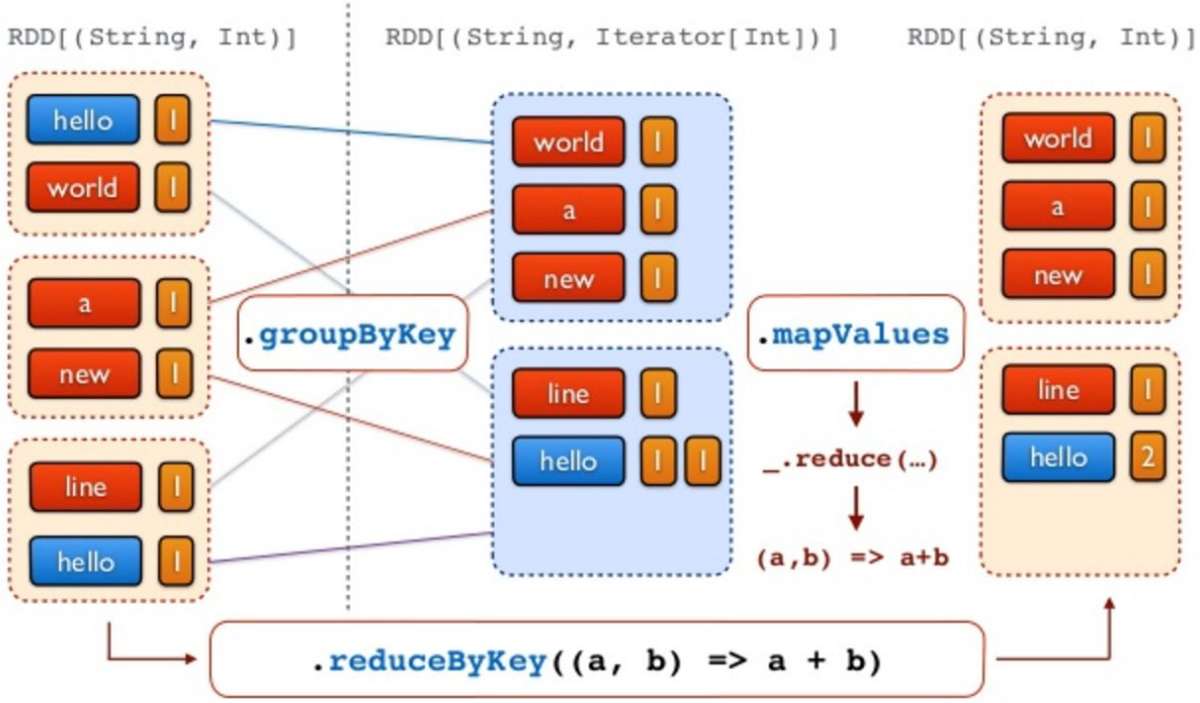

Задание: логистическая регрессия

$$y(x, w) = \frac{1}{1 + exp(-xw^T)}$$

$$w = w - \lambda \frac{1}{N} \sum_{i=1}^{N} (y(x_i) - t_i) x_i$$

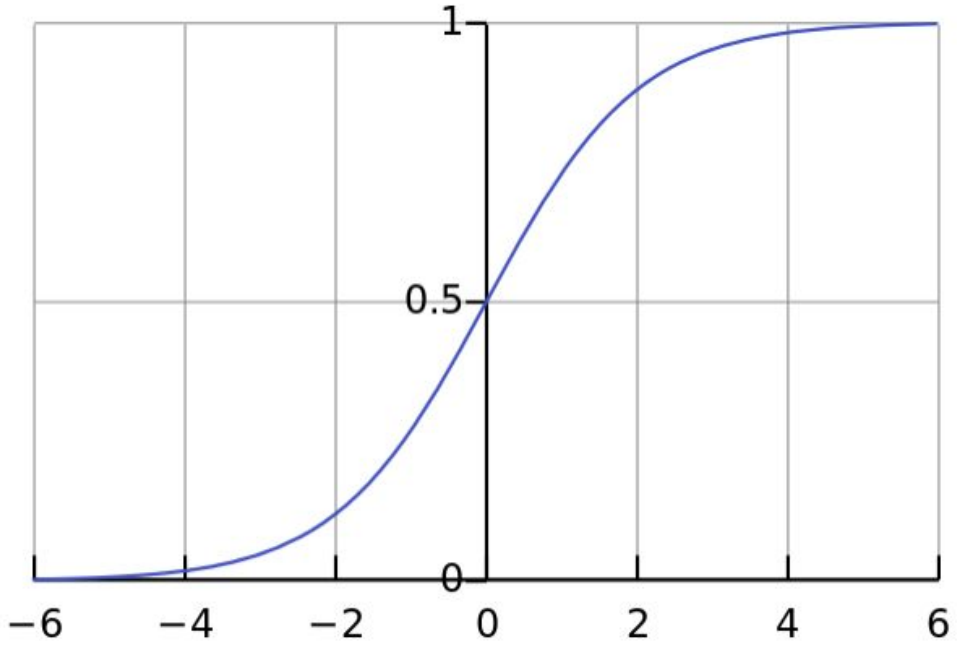

Задание: логистическая регрессия